Наша локальная RAG-система

Мы разработали контур поиска и проверки фактов для технических документов.

Мы представляем работу РУДН, Факультета ИИ, группы ЗПИбд-03-25.

Мы объединяем локальный инференс, ссылки на источники и проверяемые отказы.

Какие барьеры мы снимаем

Мы сохраняем документы внутри локального контура после подготовки зависимостей.

Мы проверяем утверждения вместо доверия свободной генерации.

Мы показываем источники и причины отказа в нашем Web-интерфейсе.

Как мы строим наш конвейер

Мы сохраняем разделы, абзацы и метаданные PDF / DOCX / TXT / MD.

Мы объединяем BM25 и BGE-M3 через RRF, затем применяем BGE-Reranker.

Мы генерируем Qwen2.5-14B и проверяем утверждения через mDeBERTa-v3 NLI.

Как мы контролируем утверждения

В QA мы требуем P(entailment) > 0,4 и P(contradiction) < 0,2.

В саммаризации мы удаляем contradiction > 0,3; neutral допускаем.

Мы удаляем смысловые повторы при cosine > 0,85. Мы не заявляем безошибочность NLI.

Что мы измерили на holdout

Мы получили Hit@5 = 100%: 7 из 7 положительных вопросов.

Мы выдали ответы на 5/7 вопросов и корректно отказали на 3/3 негативных.

Мы получили MRR@5 = 0,8214; nDCG@5 = 0,7670; p50 = 15,31 с.

Мы использовали ИИ-подготовленные QA по тому же корпусу, без экспертной валидации.

Какие метрики мы ставим целью

Мы сохраняем цели аннотации: Recall 91,5% и галлюцинации < 2,3%.

Мы планируем проверить Ragas Faithfulness 0,67 → 0,92 и Context Precision 0,89.

Мы не выводим эти показатели из Hit@5 или трёх негативных тестов.

Мы уточним базу сравнения для заявленного прироста точности на 25%.

Как мы разместили наш стенд

Мы используем RTX 5060 Laptop, 8 ГБ VRAM, Blackwell sm_120 и BF16.

Мы запускаем llama-server: -ngl 35 -c 4096 -b 128 -ub 64 -np 1.

Мы разделяем один экземпляр моделей между запросами Streamlit и контролируем пакеты.

Что мы показываем в демонстрации

Мы задаём вопрос о HTTP 204 и раскрываем источник [S1] и NLI-проверку.

Мы переключаемся на саммаризацию с MMR и удалением повторов.

Мы загружаем DOCX и показываем пропуск повторной загрузки по SHA-256.

Мы поставляем код, тесты, публичный корпус и SHA-256-манифест без весов и секретов.