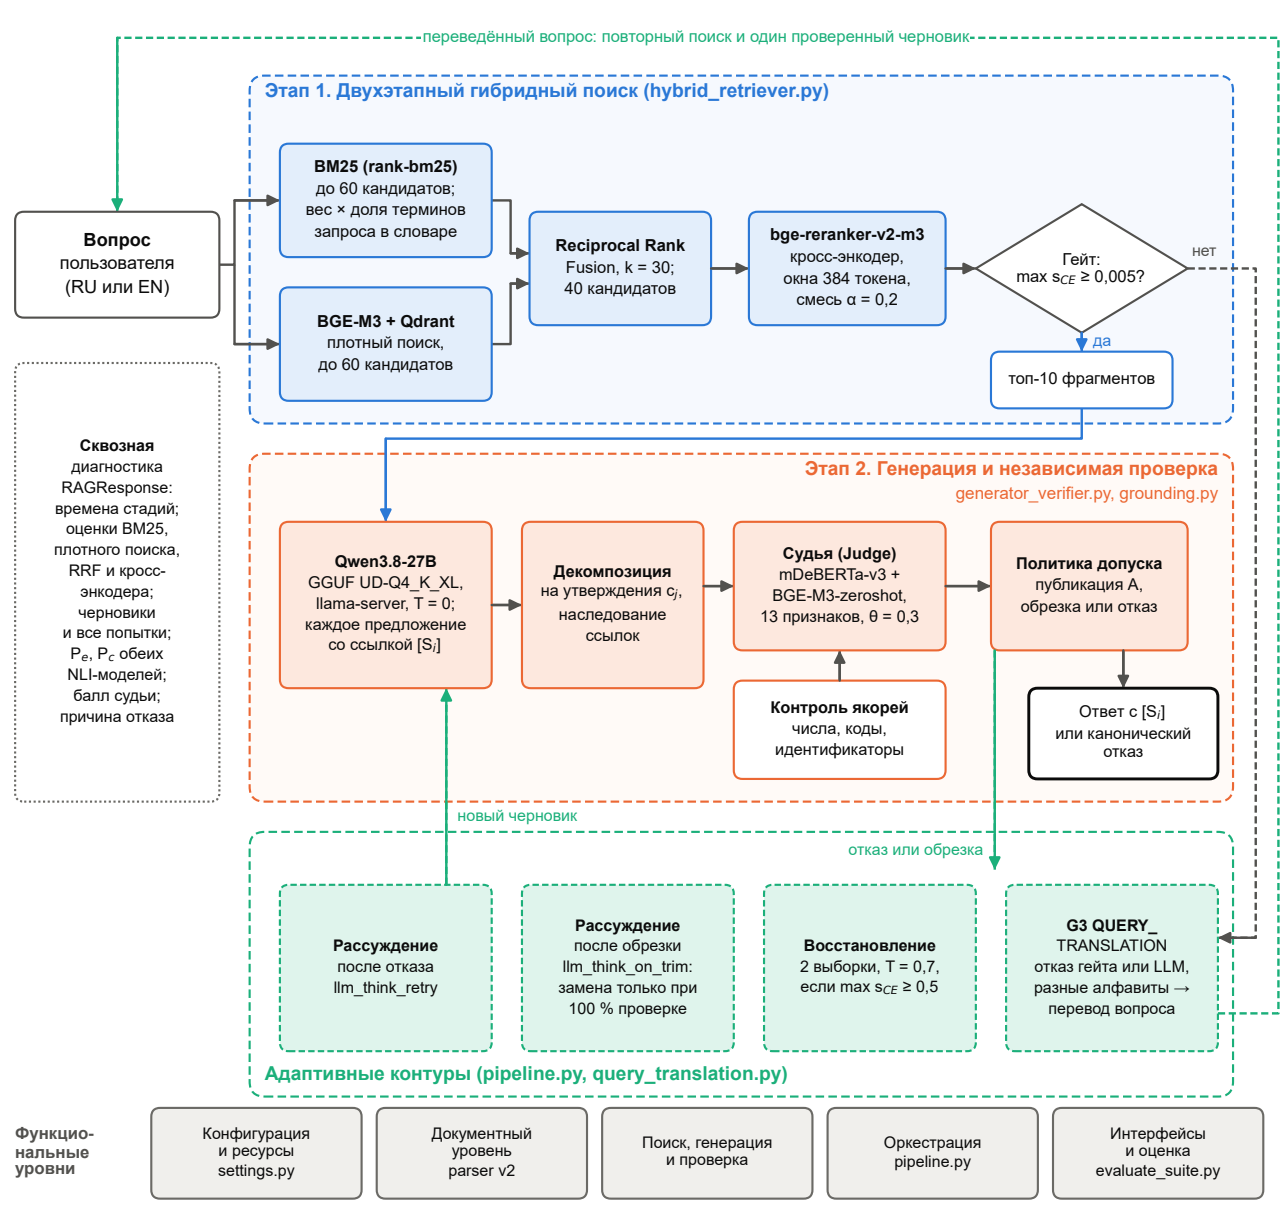

переведённый вопрос: повторный поиск и один проверенный черновик
Этап 1. Двухэтапный гибридный поиск (hybrid_retriever.py)
Вопрос пользователя (RU или EN)
BM25 (rank-bm25) до 60 кандидатов; вес × доля терминов запроса в словаре
BGE-M3 + Qdrant плотный поиск, до 60 кандидатов
Reciprocal Rank Fusion, k = 30; 40 кандидатов
bge-reranker-v2-m3 кросс-энкодер, окна 384 токена, смесь α = 0,2
Гейт: max s_{CE} ≥ 0,005?
нет
да
топ-10 фрагментов
Сквозная диагностика RAGResponse: времена стадий; оценки BM25, плотного поиска, RRF и кросс-энкодера; черновики и все попытки; P_e, P_c обеих NLI-моделей; балл судьи; причина отказа
Этап 2. Генерация и независимая проверка
generator_verifier.py, grounding.py
Qwen3.8-27B GGUF UD-Q4_K_XL, llama-server, T = 0; каждое предложение со ссылкой [S_i]
Декомпозиция на утверждения c_j, наследование ссылок
Судья (Judge) mDeBERTa-v3 + BGE-M3-zeroshot, 13 признаков, θ = 0,3
Политика допуска публикация A, обрезка или отказ
Контроль якорей числа, коды, идентификаторы
Ответ с [S_i] или канонический отказ
новый черновик
отказ или обрезка
Рассуждение после отказа llm_think_retry
Рассуждение после обрезки llm_think_on_trim: замена только при 100 % проверке
Восстановление 2 выборки, T = 0,7, если max s_{CE} ≥ 0,5
G3 QUERY_TRANSLATION отказ гейта или LLM, разные алфавиты → перевод вопроса
Адаптивные контуры (pipeline.py, query_translation.py)
Функцио-нальные уровни
Конфигурация и ресурсы settings.py
Документный уровень parser v2
Поиск, генерация и проверка
Оркестрация pipeline.py
Интерфейсы и оценка evaluate_suite.py