
Файл
TXT, MD, PDF с текстовым слоем, DOCX
Проверка
формат, размер, ≤ 500 страниц; снимок файла
SHA-256
идентификатор документа
Хеш уже в индексе?
да
нет
пропуск: векторы не пересчитываются
Структурный парсинг
(parser v2)
section_path, страницы; таблицы с подписью и шапкой; защита от ложных заголовков
Сегментация
окна 320/384 токена BGE, перекрытие 50 целыми предложениями; шапка таблицы в каждом фрагменте
Индексация
эмбеддинги BGE-M3 → Qdrant; пересборка BM25; число фрагментов в метаданных
Документ доступен поиску только после полной индексации; прерванная индексация исключает его до повторной загрузки
Изменённое содержимое - новый хеш и новая версия документа; тот же файл под другим именем распознаётся по хешу