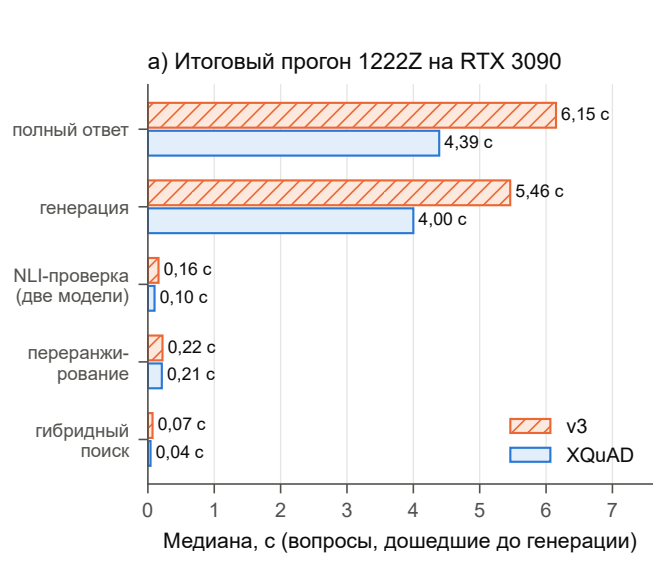
а) Итоговый прогон 1222Z на RTX 3090
полный ответ
генерация
NLI-проверка (две модели)
переранжи-рование
гибридный поиск
6,15 с
4,39 с
5,46 с
4,00 с
0,16 с
0,10 с
0,22 с
0,21 с
0,07 с
0,04 с
v3
XQuAD
0
1
2
3
4
5
6
7
Медиана, с (вопросы, дошедшие до генерации)

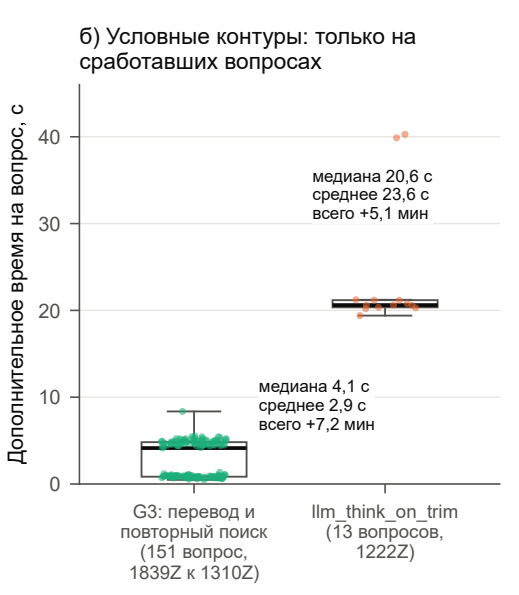
б) Условные контуры: только на сработавших вопросах
Дополнительное время на вопрос, с
0
10
20
30
40
медиана 20,6 с
среднее 23,6 с
всего +5,1 мин
медиана 4,1 с
среднее 2,9 с
всего +7,2 мин
G3: перевод и повторный поиск (151 вопрос, 1839Z к 1310Z)
llm_think_on_trim (13 вопросов, 1222Z)