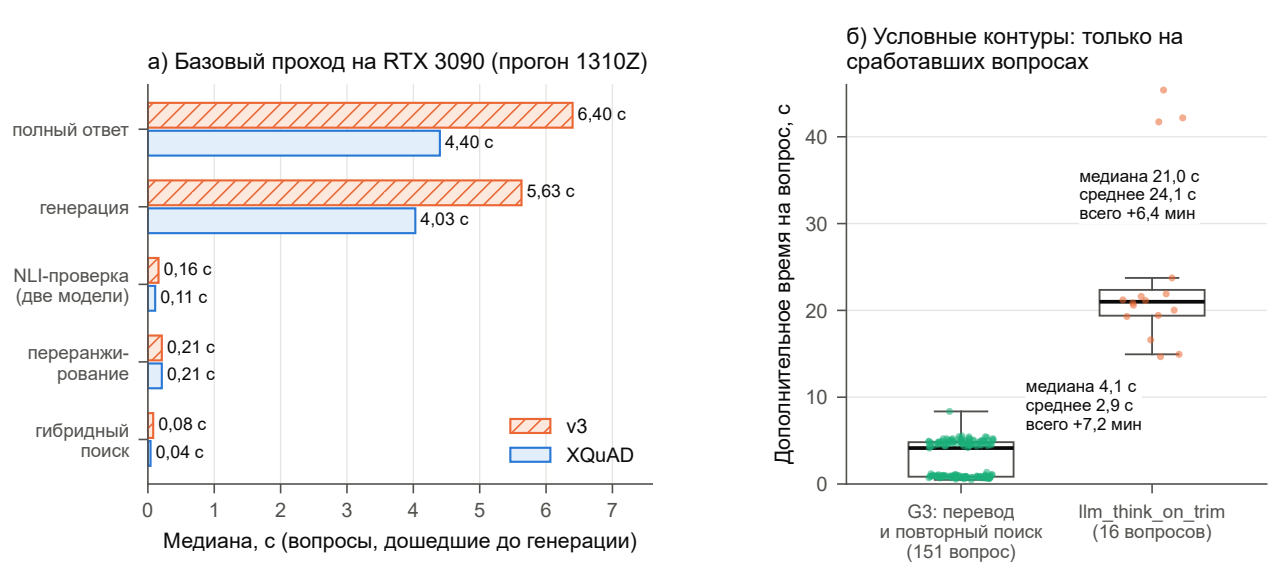
а) Базовый проход на RTX 3090 (прогон 1310Z)
полный ответ
генерация
NLI-проверка (две модели)
переранжи-рование
гибридный поиск
6,40 с
4,40 с
5,63 с
4,03 с
0,16 с
0,11 с
0,21 с
0,21 с
0,08 с
0,04 с
v3
XQuAD
0
1
2
3
4
5
6
7
Медиана, с (вопросы, дошедшие до генерации)
б) Условные контуры: только на сработавших вопросах
Дополнительное время на вопрос, с
0
10
20
30
40
медиана 21,0 с
среднее 24,1 с
всего +6,4 мин
медиана 4,1 с
среднее 2,9 с
всего +7,2 мин
G3: перевод и повторный поиск (151 вопрос)
llm_think_on_trim (16 вопросов)